

**Universidade Estadual de Maringá**  
**Departamento de Estatística**  
**Disciplina:** 8067 – Estatística Computacional II  
**Professor:** Dr. Josmar Mazucheli  
**Acadêmico:** André Felipe B. Menezes

## **Métodos de Estimação para os Parâmetros da Distribuição Gama Inversa**

Maringá  
Agosto de 2016

# Conteúdo

<b>1</b>	<b>Distribuição Gama Inversa</b>	<b>2</b>
1.1	Implementação SAS® . . . . .	3
1.2	Implementação R . . . . .	4
<b>2</b>	<b>Métodos de Estimação</b>	<b>6</b>
2.1	Máxima Verossimilhança (MLE) . . . . .	6
2.1.1	Implementação SAS® . . . . .	6
2.1.2	Implementação R . . . . .	8
2.2	Produto Máximo de Espaçamento (MPS) . . . . .	9
2.2.1	Implementação SAS® . . . . .	10
2.2.2	Implementação R . . . . .	11
2.3	Método dos Percentis (PCE) . . . . .	12
2.3.1	Implementação SAS® . . . . .	12
2.3.2	Implementação R . . . . .	13
2.4	Mínimos Quadrados Ordinários (OLS) . . . . .	14
2.4.1	Implementação SAS® . . . . .	14
2.4.2	Implementação R . . . . .	15
2.5	Mínimos Quadrados Ponderados (WLS) . . . . .	16
2.5.1	Implementação SAS® . . . . .	16
2.5.2	Implementação R . . . . .	17
<b>3</b>	<b>Estudo de Simulação</b>	<b>17</b>

# 1 Distribuição Gama Inversa

A família de distribuições gama inversa ou gama invertida é bastante útil nas áreas de análise de sobrevivência, confiabilidade e inferência Bayesiana. Glen (2011) propõe a distribuição gama inversa como um modelo do tempo de vida no contexto de estudos em confiabilidade e sobrevivência. Por outro lado, Gelman (2006) mostra aplicações da distribuição gama inversa como sendo uma a priori não informativa. Alguns exemplos de aplicação da distribuição gama inversa são: teste de tempo de vida, problemas de controle de qualidade e tempo de falha de um determinado material (LIMA; FARIAS, 2013).

Entre as características marcantes da distribuição gama inversa está seu elevado grau de assimetria e curtose. Como bem especifica Lima e Farias (2013), a distribuição gama inversa tem origem a partir da transformação recíproca de uma variável com distribuição pertencente a família de distribuições gama.

Dessa forma, considere que variável aleatória  $X$  tem distribuição gama com função densidade de probabilidade dada por:

$$f(x | \alpha, \beta) = \frac{1}{\Gamma(\alpha) \beta^\alpha} x^{\alpha-1} \exp(-x/\beta), \quad x > 0. \quad (1)$$

Sendo que  $\alpha > 0$  é o parâmetro de forma e  $\beta > 0$  é denominado parâmetro de escala (CASELLA; BERGER, 2011).

Assim a seguinte transformação de variável

$$Y = \frac{1}{X}. \quad (2)$$

define a distribuição gama inversa  $GI(\alpha, \beta)$ , com função densidade de probabilidade dada por:

$$f(y | \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{-(\alpha+1)} \exp(-\beta/y), \quad x > 0. \quad (3)$$

De (3) temos que a função de distribuição acumulada da distribuição gama inversa é:

$$F(y | \alpha, \beta) = \int_0^y \frac{\beta^\alpha}{\Gamma(\alpha)} u^{-(\alpha+1)} \exp(-\beta/u) du = \frac{\Gamma(\alpha, \frac{\beta}{y})}{\Gamma(\alpha)} \quad (4)$$

Sendo que o numerador é a função gama incompleta superior e o denominador é a função gama.

Conforme o método da transformação inversa (RUBINSTEIN; KROESE, 2008, p. 51) valores pseudos aleatórios da distribuição gama inversa podem ser gerados a partir da equação.

$$y = F^{-1}(U | \alpha, \beta), \quad U \sim Uniforme(0, 1) \quad (5)$$

## 1.1 Implementação SAS<sup>®</sup>

Uma maneira alternativa de criar alguma distribuição de probabilidade não implementada pelo SAS<sup>®</sup> é via SAS/IML<sup>®</sup>. No que se refere a distribuição gama inversa (3) o seguinte código define as funções densidade (d), distribuição (p), quantil (q) e variate (r).

Código – SAS 1.1: Funções da Distribuição Gama Inversa

```
proc iml;
/*Funcao Densidade de Probabilidade*/
start dinvgama(x, alpha, beta);
    pdf = ((beta##alpha)/gamma(alpha)) # x##(-alpha - 1) #
        exp(-beta/x);
    return(pdf);
finish;
/*Funcao Distribuicao Acumulada*/
start pinvgama(q,alpha,beta);
    cdf = 1 - cdf("GAMMA",1/q,alpha,1/beta);
    return(cdf);
finish;
/*Funcao Quantil*/
start qinvgama(p,alpha,beta);
    qf      = 1/quantile("GAMMA",1-p,alpha,1/beta);
    return(qf);
finish;
/*Funcao Variate*/
start rinvgama(n,alpha,beta);
    aux      = j(n,1);
    call randgen(aux, "Gamma", alpha, 1/beta);
    rg       = 1/aux;
    return(rg);
finish;
quit;
```

## 1.2 Implementação R

Já no software R a família de funções `d`, `p`, `q`, `r` da distribuição gama inversa foi implementada com o código abaixo:

Código – R 1.1: Funções da Distribuição Gama Inversa

```
# Funcao densidade de probabilidade
dinvgamma <- function(x, alpha, beta){
  (beta^alpha)/gamma(alpha)*x^(-alpha - 1)*exp(-beta/x)
}

# Funcao distribuicao acumulada
pinvgama <- function(q, alpha, beta){
  1 - pgamma(1/q, alpha, beta)
}

# Funcao quantil
qinvgama <- function (p, alpha, beta) {
  1/qgamma(1 - p, alpha, beta)
}

# Funcao variate
rinvgamma <- function(n, alpha, beta){
  1/rgamma(n, alpha, beta)
}
```

Na Figura 1 observamos os gráficos da função densidade (3) e função distribuição acumulada (4) da distribuição gama inversa para diferentes valores dos parâmetros  $\alpha$  e  $\beta$ . Observa-se que a medida que  $\alpha$  aumenta mais assimétrica a distribuição se torna.




Figura 1: Função densidade de probabilidade e Função distribuição acumulada da distribuição gama inversa

## 2 Métodos de Estimação

Nesta seção serão apresentados cinco métodos de estimação para os parâmetros de distribuições de probabilidade. Esta seção está organizada com a explicação teórica dos métodos, a implementação computacional nos softwares SAS<sup>®</sup> e R e, ao final um exemplo com a distribuição gama inversa.

### 2.1 Máxima Verossimilhança (MLE)

Sejam  $y_1, y_2, \dots, y_n$  um conjunto de observações provenientes de (3) a função de verossimilhança de  $(\alpha, \beta)$  pode ser escrita na forma:

$$L(\alpha, \beta \mid \mathbf{y}) = \left( \frac{\beta^\alpha}{\Gamma(\alpha)} \right)^n \exp \left( -\beta \sum_{i=1}^n \frac{1}{y_i} \right) \prod_{i=1}^n (y_i)^{-(\alpha+1)} \quad (6)$$

Aplicando a função logarítmica em (6) têm-se a função log-verossimilhança:

$$l(\alpha, \beta \mid \mathbf{y}) = n \alpha \log(\beta) - n \log(\Gamma(\alpha)) - \beta \sum_{i=1}^n \frac{1}{y_i} - (\alpha + 1) \sum_{i=1}^n \log(y_i) \quad (7)$$

Sabe-se que as estimativas de máxima verossimilhança são os valores de  $\alpha, \beta$  que maximizam a função verossimilhança ou a função log-verossimilhança da amostra. Fazendo com que os dados observados sejam tão prováveis quanto possíveis. Assim os valores de  $\hat{\alpha}$  e  $\hat{\beta}$  são as raízes do vetor gradiente, dado por:

$$U(\beta_0, \beta_1, \sigma^2, \mathbf{y}) = \begin{cases} n \log(\beta) - n \psi(\alpha) - \sum_{i=1}^n \log(y_i) \\ \frac{n \alpha}{\beta} - \sum_{i=1}^n \frac{1}{y_i} \end{cases} \quad (8)$$

em que  $\psi$  é a função digama.

#### 2.1.1 Implementação SAS<sup>®</sup>

Em relação ao software SAS<sup>®</sup> utilizamos duas formas para encontrar as estimativas de máxima verossimilhança de  $\alpha$  e  $\beta$ . Por meio do SAS/IML<sup>®</sup> e via SAS-data-step utilizando a `proc nlp`.

No SAS/IML<sup>®</sup> a priori deve-se construir a função objetiva (7), determinar os valores iniciais (*ini*), o suporte dos parâmetros (*sup*) a natureza do problema (*max*) e por fim, chamar (*call*) o procedimento *nlpnra*. As estimativas de  $\alpha$  e  $\beta$  são guardadas na matriz *res\_mle* e o número de iterações na matriz *it*.

#### Código – SAS 2.1: MLE

```
/*Via SAS/IML */
proc iml;
start MLE(par) global(x);
    alpha    = par[1];
    beta     = par[2];
    n        = nrow(x);
    l        = n#(alpha#log(beta) - log(gamma(alpha))) -
        beta#sum(1/x) - (alpha + 1)#sum(log(x));
    return (l);
finish;

call randseed(1515);
x = rinvgama(100,5,3);

sup = { 1e-10    1e-10,
        .        .};
ini = {5 3};
max = {1};
call nlpnra(it, res_mle, "MLE", ini, max, sup);
print it res_mle;
quit;

/*Via SAS-data-step*/
data simulados(keep=y);
    call streaminit(1515);
    do i=1 to 100;
        x = rand("Gamma",5,1/3);
        y = 1/x;
        output;
    end;
run;

proc nlp data=simulados tech=nrr;
    max ll;
    bounds alpha > 1e-10, beta > 1e-10;
    parms alpha=5, beta=3;
    ll = alpha*log(beta) + log(gamma(alpha)) - beta*(1/y) -
        (alpha+1)*log(y);
run;
```



### 2.1.2 Implementação R

No ambiente estatístico R existem milhares de funções para encontrar os estimadores de máxima verossimilhança. Neste trabalho, optou-se por utilizar a função `optim` a qual minimiza ou maximiza a função objetiva. Além disso, utilizou-se também a função `fitdist` da biblioteca `fitdistrplus`.

Por meio da função `optim` é necessário informar a função objetiva, isto é, a log-verossimilhança (6), os valores iniciais para  $\alpha$  e  $\beta$ , e a opção `control = list(fnscale=-1)` para determinar que a função `logLH` deve ser maximizada.

Por outro lado, via função `fitdist` é obrigatório existir as funções `d` e `p` da distribuição gama inversa e os valores iniciais para os parâmetros.

O código abaixo apresenta as estimativas de máxima verossimilhança de  $\alpha$  e  $\beta$  para dados pseudos aleatórios da distribuição gama inversa:

Código – R 2.1: MLE

```
library(fitdistrplus)

logLH <- function(par, x){
  alpha <- par[1]
  beta <- par[2]
  n <- length(x)
  return(n*(alpha*log(beta) - log(gamma(alpha))) - beta*sum(1/x) -
        (alpha + 1)*sum(log(x)))
}

set.seed(1502)
y <- rinvgamma(100, 5, 3)

optim(par = c(5, 3), fn = logLH, x=y, control = list(fnscale=-1))
fitdist(data = y, distr = "invgamma", start = c(5, 3), method =
  "mle")
```

## 2.2 Produto Máximo de Espaçamento (MPS)

Considerado um método alternativo a máxima verossimilhança, o método do produto máximo de espaçamento (*maximum product of spacing*) de acordo com Mazucheli, Ghitany e Louzada (2016) foi desenvolvido por Cheng e Amin em 1979. O MPS busca encontrar a função de distribuição acumulada tal que os espaçamentos sejam aproximadamente com o mesmo comprimento, para isso deve-se maximizar a média geométrica dos espaçamentos ( $D_i$ ).

Dessa forma, dada uma amostra aleatória  $y_1, y_2, \dots, y_n$  de (3), sejam  $y_{(1)}, y_{(2)}, \dots, y_{(n)}$  a amostra correspondente ordenada. Definimos os espaçamentos uniformes sendo:

$$D_i(\alpha, \beta) = F(y_{(i)} \mid \alpha, \beta) - F(y_{(i-1)} \mid \alpha, \beta), \quad i = 1, 2, \dots, n. \quad (9)$$

em que  $F(y_{(0)} \mid \alpha, \beta) = 0$  e  $F(y_{(n+1)} \mid \alpha, \beta) = 1$ .

Portanto, conforme definem Cheng e Amin (1979) o estimador de espaçamento máximo de  $\alpha$  e  $\beta$  são os valores que maximizam a média geométrica dos espaçamentos, isto é:

$$G(\alpha, \beta) = \left( \prod_{i=1}^{n+1} D_i(\alpha, \beta) \right)^{\frac{1}{n+1}} \quad (10)$$

No qual é equivalente a maximizar o logaritmo da média geométrica (10):

$$H(\alpha, \beta) = \frac{1}{n+1} \sum_{i=1}^n \log D_i(\alpha, \beta) \quad (11)$$

Os autores explicam que em virtude da transformação uniformizante (*probability integral transform*) os “espaçamentos” entre cada observação devem ser uniformemente distribuídos. Isso implica que a diferença entre os valores da função de distribuição acumulada em observações consecutivas devem ser iguais.

### 2.2.1 Implementação SAS®

É possível via SAS/IML® implementarmos a função (11) e maximizá-la utilizando. No código abaixo temos sua implementação e um exemplo.

Código – SAS 2.2: MPS

```
proc iml;
start MPS(par) global(x);
    call sort(x);
    alpha = par[1];
    beta = par[2];
    xin = {0} // x;
    n = nrow(xin);
    i1 = 2:n;
    i2 = 1:(n-1);
    Di = pinvgama(xin[i1], alpha, beta) - pinvgama(xin[i2],
        alpha, beta);
    G = (1/(n+1)) # sum(log(Di));
    return(G);
finish;

/*Exemplo*/
call randseed(1515);
x = rinvgama(100,2,3); /*Simulando Dados*/

sup = { 0    0,
        .    .};
ini = {2 3};
max = {1};
call nlpnra(it, res_mps, "MPS", ini, max, sup);
print it res_mps;
quit;
```

### 2.2.2 Implementação R

A implementação do MPS no R foi realizada escrevendo a função (11) e por meio da função `optim` maximizando a função MPS. Note que na função MPS é necessário informar a função de distribuição acumulada (`p`).

Código – R 2.2: MPS

```
MPS <- function(par, x, p){  
  xin <- sort(x)  
  n <- length(xin)  
  Di <- diff(c(0, p(xin, par[1], par[2]), 1))  
  H <- (1/(n+1)) * sum(log(Di))  
  return(H)  
}  
  
set.seed(1502)  
y <- rinvgamma(100, 5, 3)  
  
optim(par = c(5, 3), fn = MPS, p=pinvgamma, x=y, control =  
  list(fnscale=-1))
```

## 2.3 Método dos Percentis (PCE)

Conforme Gupta e Kundu (2001) este método foi explorado inicialmente por Kao em 1958 na estimação dos parâmetros da distribuição Weibull.

Em sua essência o método dos percentis procura minimizar a diferença entre os percentis amostrais ( $y_{(i)}$ ) e os percentis teóricos.

Considere que  $p_i$  seja um estimador para  $F(y_{(i)} | \alpha, \beta)$  (4), então as estimativas pelo método dos percentis de  $\alpha$  e  $\beta$  podem ser encontradas minimizando a função:

$$P(\alpha, \beta) = \sum_{i=1}^n (y_{(i)} - F^{-1}(p_i | \alpha, \beta))^2 \quad (12)$$

em que  $p_i = \frac{i}{n+1}$  e  $F^{-1}(p_i | \alpha, \beta)$  é dado em (5).

A distribuição gama inversa não possui função quantil com forma explícita, isso em alguns casos pode levar a complicações em relação a este método.

### 2.3.1 Implementação SAS®

É possível com auxílio do SAS/IML® implementarmos o método dos percentis. Na sequência o código com um exemplo prático:

Código – SAS 2.3: PCE

```
proc iml;
start PCE(par) global(x);
    call sort(x);
    alpha = par[1];
    beta = par[2];
    n = nrow(x);
    i = 1:n;
    pi = i/(n+1);
    P = sum((t(x) - qinvgamma(pi,alpha,beta))##2);
    return(P);
finish;

/*Exemplo*/
call randseed(1515);
x = rinvgama(100,2,3);

sup = { 0    0,
        .    .};
ini = {2 3};
min = {0};
call nlpnra(it, res_pce, "PCE", ini, min, sup);
print it res_pce;
quit;
```

### 2.3.2 Implementação R

O método dos percentis pode ser implementado no R escrevendo a função (12) e minimizando ela por meio do `optim`. Ressalta-se, que a função `PCE` é genérica, isto é, para qualquer distribuição, uma vez que o parâmetro `q` determina a função quantil da distribuição de probabilidade.

Código – R 2.3: PCE

```
PCE <- function(par, x, q){  
  xin <- sort(x)  
  n <- length(xin)  
  i <- 1:n  
  pi <- i / (n+1)  
  P <- sum((xin - q(pi, par[1], par[2]))^2)  
  return(P)  
}  
  
set.seed(1502)  
y <- rinvgama(100, 5, 3)  
  
optim(par = c(5, 3), fn = PCE, x=y, q=qinvgama)
```

## 2.4 Mínimos Quadrados Ordinários (OLS)

Originalmente proposto por Swain, Venkatraman e Wilson (1988) para estimar os parâmetros da distribuição beta, o método dos mínimos quadrados faz uso da função de distribuição acumulada das estatísticas de ordem, isto é,  $F(Y_{(i)})$ . Conforme Larson (1974, p. 355), para uma amostra de tamanho  $n$  temos que  $F(Y_{(i)}) \sim \text{Beta}(i, n - i + 1)$ . Dessa forma, têm-se que:

$$\mathbb{E}(F(Y_{(i)})) = \frac{i}{n+1}, \quad \text{Var}(F(Y_{(i)})) = \frac{i(n-i+1)}{(n+1)^2(n+2)} \quad (13)$$

Portanto, encontramos as estimativas de mínimos quadrados ordinários de  $\alpha$  e  $\beta$  minimizando a função:

$$S(\alpha, \beta) = \sum_{i=1}^n \left( F(y_{(i)} \mid \alpha, \beta) - \frac{i}{n+1} \right)^2 \quad (14)$$

em que  $F(y_{(i)} \mid \alpha, \beta)$  é a função de distribuição acumulada (4) aplicada na amostra ordenada.

### 2.4.1 Implementação SAS®

Assim como os outros métodos, o método dos mínimos quadrados ordinários pode ser implementado no SAS/IML®. A implementação juntamente com um exemplo é apresentada no código abaixo:

Código – SAS 2.4: OLS

```
OLS <- function(par, x, p){
  xin <- sort(x)
  n <- length(xin)
  i <- 1:n
  S <- sum(((p(xin, par[1], par[2])) - i/(n+1))^2)
  return(S)
}

set.seed(1502)
y <- rinvgama(50, 5, 3)

optim(par = c(5, 3), fn = OLS, x=y, p=pinvgama)
```

### 2.4.2 Implementação R

De maneira semelhante ao método dos percentis, o método dos mínimos quadrados ordinários pode ser implementado no R, escrevendo a função (14) e minimizando-a com auxílio da função `optim`.

Código – R 2.4: OLS

```
OLS <- function(par, x, p){
  xin <- sort(x)
  n <- length(xin)
  i <- 1:n
  S <- sum(((p(xin, par[1], par[2])) - i/(n+1))^2)
  return(S)
}

set.seed(1502)
y <- rinvgamma(50, 5, 3)

optim(par = c(5, 3), fn = OLS, x=y, p=pinvgamma)
```



## 2.5 Mínimos Quadrados Ponderados (WLS)

Em contrapartida ao OLS, o método de mínimos quadrados ponderados, atribui um “peso” para cada observação. Ou seja, cada observação será ponderada com sua respectiva variância.

Dessa forma, encontra-se as estimativas de mínimos quadrados ponderados minimizando a função:

$$W(\alpha, \beta) = \sum_{i=1}^n \frac{i(n-i+1)}{(n+1)^2(n+2)} \left( F(y_{(i)} | \alpha, \beta) - \frac{i}{n+1} \right)^2 \quad (15)$$

sendo  $F(y_{(i)} | \alpha, \beta)$  a função de distribuição acumulada (4) aplicada na amostra ordenada.

### 2.5.1 Implementação SAS®

Da mesma forma que os demais métodos o WLS pode ser implementado no SAS/IML®. Abaixo apresenta-se o código juntamente com um exemplo.

Código – SAS 2.5: WLS

```
WLS <- function(par, x, p){
  xin <- sort(x)
  n <- length(xin)
  i <- 1:n
  W <- sum(i*(n-i+1)/((n+1)^2*(n+2))*((p(xin,par[1],
    par[2]))-i/(n+1))^2)
  return(W)
}

set.seed(1502)
y <- rinvgama(50, 5, 3)

optim(par = c(5, 3), fn = WLS, x=y, p=pinvgama)
```

### 2.5.2 Implementação R

Analogamente ao OLS o método do mínimos quadrados ponderados é implementado no ambiente estatístico R escrevendo a função (15) e minimizando-a por meio da função `optim`.

Código – R 2.5: WLS

```
WLS <- function(par, x, p){
  xin <- sort(x)
  n <- length(xin)
  i <- 1:n
  W <- sum(i*(n-i+1)/((n+1)^2*(n+2))*((p(xin,par[1],
    par[2]))-i/(n+1))^2)
  return(W)
}

set.seed(1502)
y <- rinvgamma(50, 5, 3)

optim(par = c(5, 3), fn = WLS, x=y, p=pinvgamma)
```

## 3 Estudo de Simulação

Nesta seção apresentaremos os resultados do estudo de simulação Monte Carlo, cujo objetivo foi comparar os métodos de estimação discutidos nas seções anteriores em termos de tendenciosidade e consistência.

Este estudo foi conduzido variando o tamanho amostral,  $n = 10, 20, 40, 60, 80$  e  $100$ , o parâmetro de escala  $\alpha = 1, 2, 3$  e  $4$  e fixado o parâmetro de forma  $\beta = 1$  da distribuição gama inversa (3).

Para cada cenário  $(n, \alpha, \beta)$  foram simuladas  $B = 10000$  amostras pseudas aleatórias da distribuição gama inversa, pelo método discutido em (5). Toda simulação foi desenvolvida no ambiente estatístico R e com auxílio da função `optim` e dos métodos implementados nas seções anteriores.

Como o intuito é verificar as propriedades assintóticas de tendenciosidade e consistência dos métodos de estimação, foram calculados os vícios e erros quadráticos médios das estimativas dos parâmetros  $(\alpha$  e  $\beta)$ , conforme as equações 16 e 17 respectivamente.

$$\mathcal{B}(\hat{\alpha}) = \frac{1}{M} \sum_{i=1}^M (\hat{\alpha}_i - \alpha), \quad \mathcal{B}(\hat{\beta}) = \frac{1}{M} \sum_{i=1}^M (\hat{\beta}_i - \beta) \quad (16)$$

$$\text{EQM}(\hat{\alpha}) = \frac{1}{M} \sum_{i=1}^M (\hat{\alpha}_i - \alpha)^2, \quad \text{EQM}(\hat{\beta}) = \frac{1}{M} \sum_{i=1}^M (\hat{\beta}_i - \beta)^2 \quad (17)$$

Nas Figuras 2 à 5 são apresentados os comportamentos assintóticos dos vícios ( $\mathcal{B}$ ) e erros quadráticos médios (EQM) de  $\alpha$  e  $\beta$  para os diferentes cenários e métodos de estimação.

Em relação ao vício de  $\alpha$ , observa-se pela Figura 2, que os métodos MLE, OLS e WLS são assintoticamente não viesados em todos os cenários. Em contrapartida, os métodos MPS e PCE são assintoticamente viesados negativamente, isto é, em média os estimadores não atingem o verdadeiro valor do parâmetro.

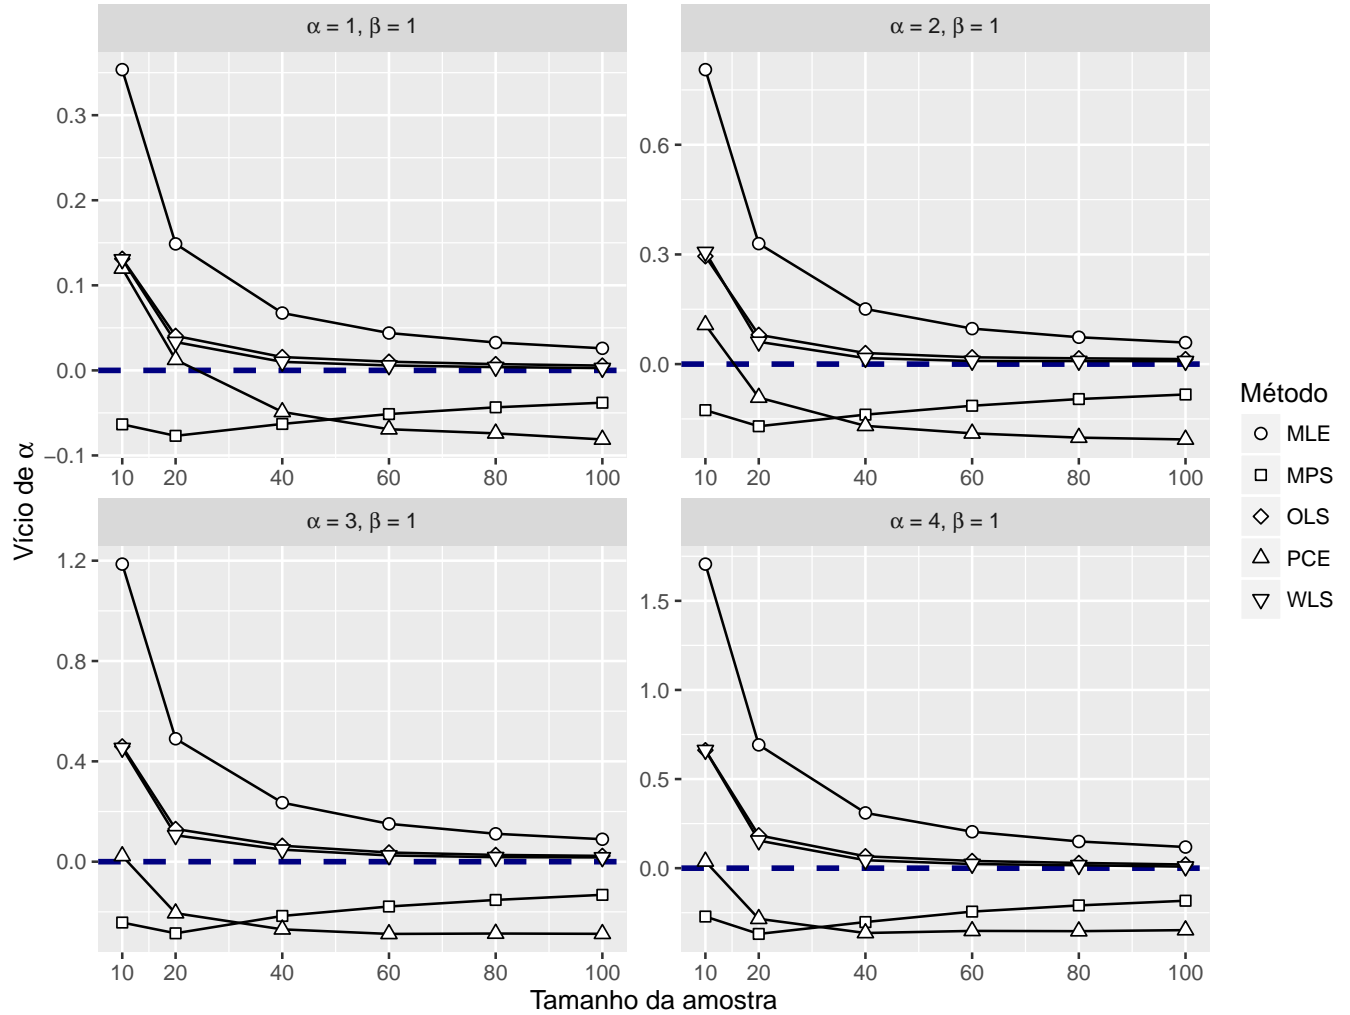


Figura 2: Vícios estimados de  $\alpha$

Verifica-se na Figura 3 que, embora os métodos MLE, OLS e WLS sejam assintoticamente não viesados em termos de  $\beta$ , os métodos de mínimos quadrados (OLS e WLS) atingem mais rapidamente a não tendenciosidade comparado ao MLE. Ressalta-se que o método PCE é viesado positivamente quando  $\alpha = \beta = 1$ , no entanto, à medida que  $\alpha$  se afasta de  $\beta$  ele se torna viesado negativamente.

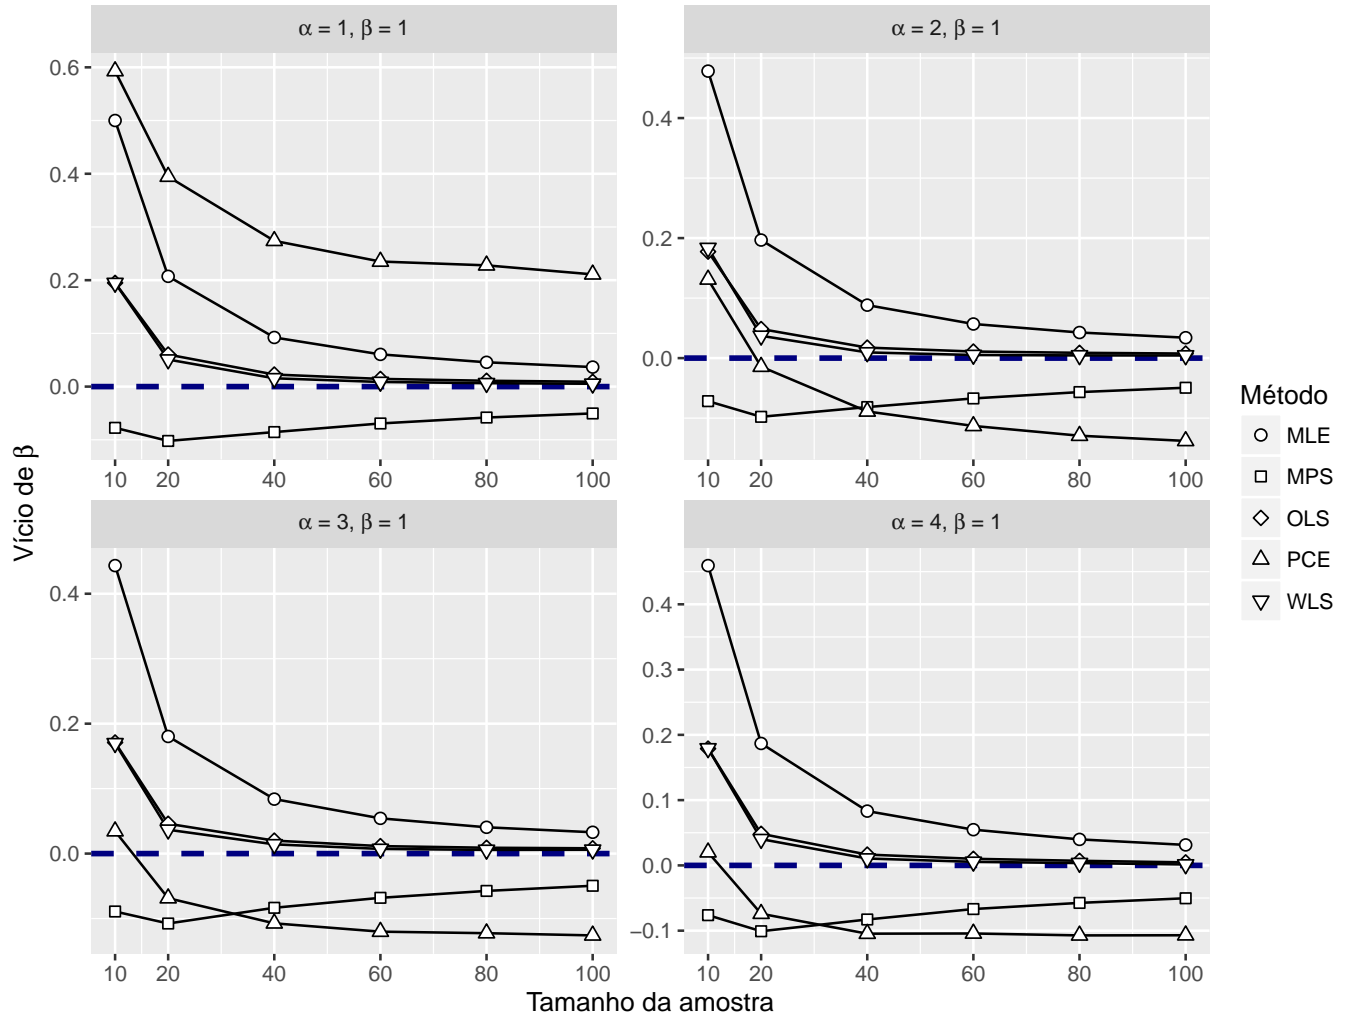


Figura 3: Vícios estimados de  $\beta$

No que tange a consistência dos métodos de estimação em termos de  $\alpha$ , pode-se observar pela Figura 4 que todos os métodos possuem a propriedade de consistência, isto é, conforme o tamanho da amostra aumenta a distribuição amostral dos estimadores torna-se cada vez mais concentrada no verdadeiro valor do parâmetro.




Figura 4: Erros quadráticos médios estimados de  $\alpha$

Observa-se na Figura 5 que os métodos MLE, MPS, OLS e WLS são consistentes. Por outro lado, percebe-se no método PCE os efeitos do parâmetro  $\alpha$  nos erros quadráticos de  $\beta$ , ou seja, a medida que  $\alpha$  se distancia de  $\beta$  o estimador PCE se torna um estimador consistente para  $\beta$ .

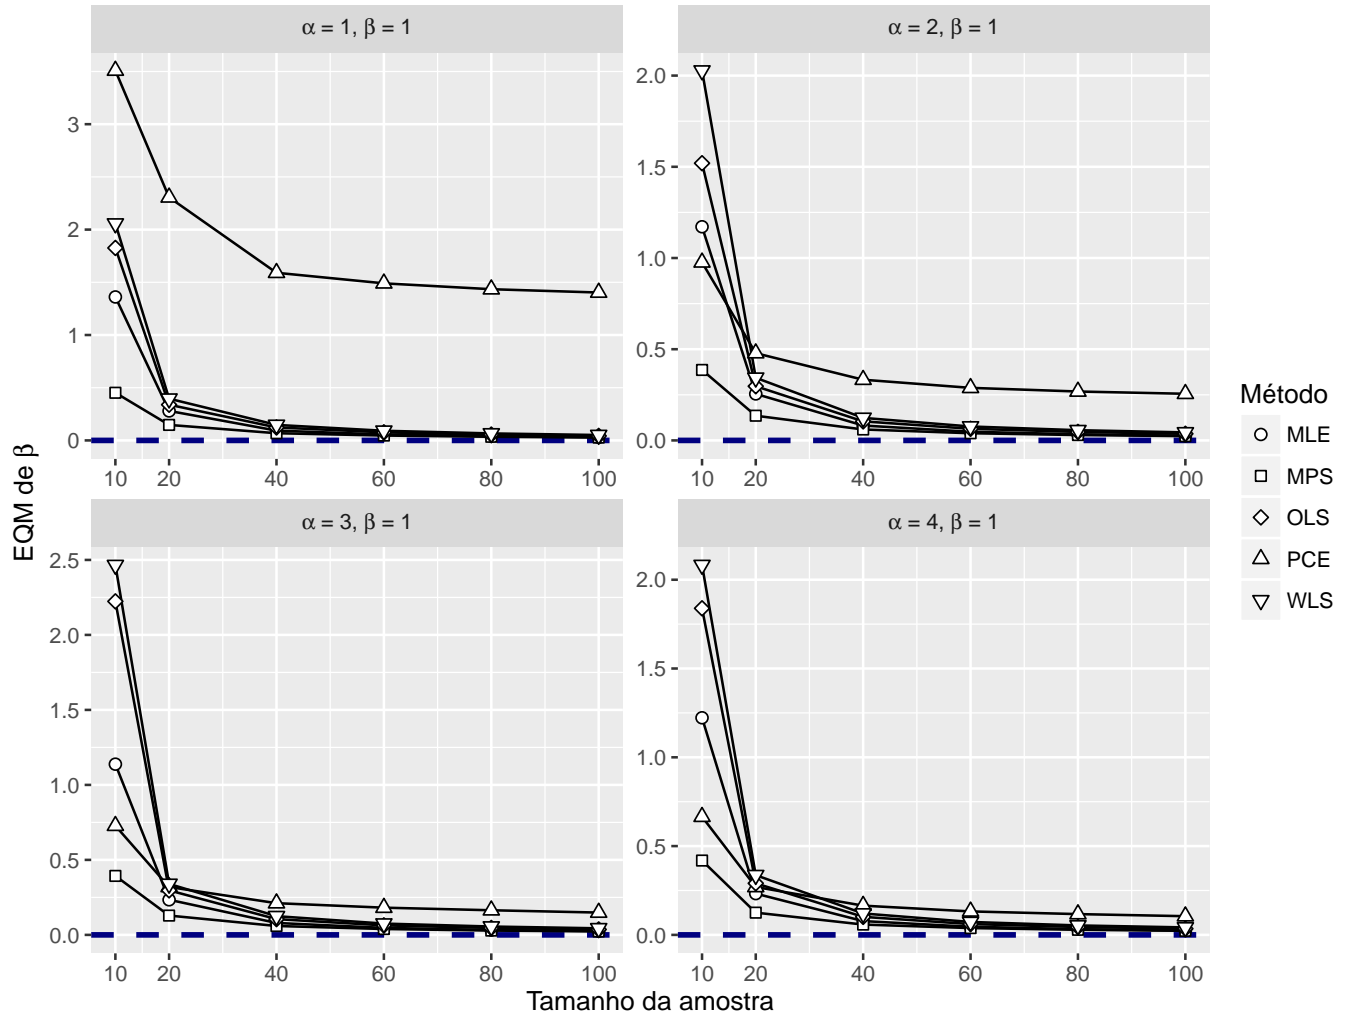


Figura 5: Erros quadráticos médios estimados de  $\beta$

## Referências

- CASELLA, G.; BERGER, R. L. **Inferência estatística**. [S.l.: s.n.], 2011.
- CHENG, R.; AMIN, N. **Maximum product of spacings estimation with application to the lognormal distribution**. 1979. 79–1 p.
- GELMAN, A. et al. **Prior distributions for variance parameters in hierarchical models (comment on article by Browne and Draper)**. [S.l.]: International Society for Bayesian Analysis, 2006. 515–534 p.
- GLEN, A. G. **On the inverse gamma as a survival distribution**. [S.l.]: J Qual Technol, 2011.
- GUPTA, R. D.; KUNDU, D. **Generalized exponential distribution: different method of estimations**. [S.l.]: Taylor & Francis, 2001. 315–337 p.
- KAO, J. H. **Computer methods for estimating Weibull parameters in reliability studies**. [S.l.]: IEEE, 1958. 15–22 p.
- LARSON, J. H. **Introduction to Probability Theory and Statistical Inference**. [S.l.]: John Wiley & Sons, 1974.
- LIMA, K.; FARIAS, R. **Distribuição Gama Inversa: conceitos e propriedades**. 2013. Acesso em: 05 de agosto de 2016. Disponível em: <http://www.rbras.org.br/rbras58/sites/default/files/submissoes>.
- MAZUCHELI, J.; GHITANY, M.; LOUZADA, F. **Comparisons of Ten Estimation Methods for the Parameters of Marshall-Olkin Extended Exponential Distribution**. [S.l.]: Taylor & Francis, 2016.
- RUBINSTEIN, R. Y.; KROESE, D. P. **Simulation and the Monte Carlo method**. [S.l.]: John Wiley & Sons, 2011. v. 707.
- SWAIN, J. J.; VENKATRAMAN, S.; WILSON, J. R. **Least-squares estimation of distribution functions in Johnson's translation system**. [S.l.]: Taylor & Francis, 1988. 271–297 p.